Fiche de description du sujet

Titre	Sortir d’un ETL visuel : modèles d’exécution, traduction et validation d’équivalence des pipelines décisionnels
Étudiant	ZIDOUR Idir
Tuteur universitaire	DOUMARD Emmanuel
Entreprise d’accueil	Adiwatt
Calendrier	Phase bibliographique : rendu le 10 novembre 2026, soutenance la semaine du 17 novembre. Phase de réalisation : rendu le 9 février 2027, soutenance la semaine du 16 février.

Contexte

Adiwatt exploite un rapport décisionnel Power BI alimenté par une chaîne en trois étages : une base brute qui reçoit les extractions du progiciel de gestion ; un workflow KNIME de 193 nœuds qui nettoie, recoupe et agrège ces données, puis écrit douze tables dans une base intermédiaire ; et le rapport lui-même, qui importe cette base et n’a pas d’autre source. Une tâche planifiée enchaîne l’ensemble quatre fois par jour sur une machine dédiée.

L’outil de flux est gratuit et l’exécution rapide ; les limites sont ailleurs. Une seule valeur mal formée interrompt tout le traitement, sans reprise possible, et le rapport reste sur les données de la veille. La logique métier n’existe que dans le graphe, sous un format propre à l’outil, et n’est lisible qu’en l’ouvrant. Le dispositif impose enfin de maintenir une machine, une base intermédiaire et deux paradigmes de transformation. L’entreprise souhaite supprimer cet étage en reconstruisant le traitement dans Power Query, le moteur de transformation de Power BI. Cette migration, engagée dans le cadre de l’apprentissage, constitue le terrain du projet.

Problématique

Une chaîne de préparation bâtie dans un outil de flux visuel peut-elle être reconstruite à l’intérieur du moteur de transformation de l’outil de restitution, sans perte d’équivalence, et à quel coût ? Trois sous-questions en découlent : (i) quelle représentation intermédiaire de la logique métier, indépendante des deux outils, suffit à engendrer le pipeline cible ; (ii) à quel niveau d’équivalence la migration doit-elle être validée, et par quel protocole, sachant que la chaîne d’origine — seule référence disponible — est appelée à disparaître ; (iii) que gagne-t-on et que perd-on, mesurément, à supprimer l’étage intermédiaire.

Objectifs

Phase bibliographique (S9). Situer le problème dans la littérature — optimisation fondée sur les capacités de la source, modèles d’exécution par flux et par évaluation paresseuse, rétro-ingénierie et traduction de pipelines, vérification d’équivalence et test différentiel — selon quatre axes transverses ; identifier les méthodes directement réutilisables ; délimiter ce que la littérature ne couvre pas. Rendu : rapport de dix pages, quinze références en accès ouvert.

Phase de réalisation (S10). Figer une référence — export daté des douze tables et mesures d’exécution — avant toute modification de la chaîne ; reconstruire la sémantique du workflow à partir de son format de sérialisation, sous la forme d’un modèle intermédiaire ; engendrer le pipeline Power Query à partir de ce modèle ; valider par comparaison ligne à ligne contre la référence, avec une tolérance déclarée à l’avance, puis par des assertions déclaratives évaluées à chaque actualisation ; mesurer le coût comparé. Critère de réussite : les douze tables coïncident avec la référence, tout écart résiduel étant expliqué. Le livrable est la solution migrée en exploitation, et non un prototype.

Mots-clés

Informatique décisionnelle · ETL · pipelines de données · délégation du calcul à la source · équivalence de requêtes · test différentiel · migration · Power Query · KNIME